Raport – Case Study

Jakub Hus IAD 420230

1. Informacje o zjawisku – PM10

Dane zawierają obserwacje dotyczące ***PM10***, czyli mieszaniny zawieszonych w powietrzu cząsteczek (pyłów) o średnicy nie większej niż ***10 µm***. Są szkodliwe z uwagi na zawartość takich elementów jak: *benzopireny*, *furany*, *dioksyny* - rakotwórcze metale ciężkie, przede wszystkim negatywnie wpływają na *układ oddechowy*. Według *WHO* norma średniego, dobowego stężenia tego pyłu wynosi ***50 µg / m^3***, a roczna ***20 µg / m^3***. W Polsce i*nformacje* o przekroczonych normach ogłasza się, gdy dobowe stężenie osiągnie ***200 µg / m^3***. Natomiast stężenie określa się jako *alarmowe*, gdy wyniesie ***300 µg / m^3***.

Pyły te mogą być zarówno pochodzenia ***naturalnego***, ***antropogenicznego***, jak i ***wtórnego***. Naturalnie pojawiają się one w powietrzu np. wskutek *pożarów* czy *wybuchów wulkanów*. Dzieje się to także poprzez działalność człowieka, np. *spalanie paliw*. Powstają także w wyniku *przemian chemicznych w atmosferze prekursorów pyłu*: dwutlenku siarki, tlenków azotu, lotnych związków organicznych czy amoniaku. Ponieważ zanieczyszczenie powietrza jest istotne dla zdrowia ludzi, w dalszej części raportu przeanalizowano dostępne dane w celu wykonania ***monitoringu jakości powietrza i wykrywania przekroczeń normy***.

2. Informacje o danych – PM10.dat

Badane dane są *podzbiorem **500** obserwacji* z zestawu danych, który służył do badania dotyczącego ***zależności zanieczyszczenia powietrza, natężenia ruchu i zmiennych meteorologicznych***. Zebrane one zostały przez ***Norweską Administrację Dróg Publicznych*** w jednej z dzielnic ***Oslo*** – ***Alnabru*** w okresie pomiędzy *październikiem 2001 roku a sierpniem 2003 roku*. Dane te zawierają następujące atrybuty:

- *Godzinowe wartości logarytmu stężenia cząstek PM10*,
- *Logarytm liczby samochodów na godzinę*,
- *Temperatura 2 metry nad poziomem gruntu (˚ C)*,
- *Prędkość wiatru (m/s)*
- *Różnica temperatur między 25 a 2 metrami nad poziomem gruntu (˚C)*,
- *Kierunek wiatru w stopniach (0-360˚)*,
- *Godzina dnia*,
- *Numer dnia (od października 2001 roku)*

Dane zostały przesłane przez ***Magne Aldrin*** (*magne.aldrin@nr.no*).

3. Przygotowanie danych – preprocessing

3.1 Wykrywanie wartości ekstremalnych

a) Statystyki opisowe

Wykrywanie wartości ekstremalnych rozpoczęto od analizy statystyk. Skupiono się na rozrzucie danych, średnim poziomie danych oraz na wartościach minimalnych i maksymalnych.

	log_PM10	log_cars	temp_2m	Wind_speed	Tempdiff_25_2m	Wind_dir	hour	dayno
Min.	0.6932	3.807	-19.000	0.300	-5.0000	5.00	1.00	32.0
1st Qu.	2.7081	6.261	-3.125	1.700	-0.2000	71.28	7.00	119.5
Median	3.2958	7.524	1.000	3.000	0.1000	101.85	13.00	212.0
Mean	3.2709	7.013	0.787	3.211	0.1548	141.09	12.45	311.4
3rd Qu.	3.8712	7.828	4.225	4.300	0.6000	216.85	18.00	511.2
Max.	5.3936	8.352	21.900	9.900	4.0000	358.00	24.00	608.0

Powyżej przedstawiono wyniki tych statystyk opisowych dla wszystkich atrybutów. Analizując te statystyki nie są widoczne żadne wartości ekstremalne lub nierealne, wszystkie są absolutnie prawdopodobne w kontekście wystąpienia w trakcie zbierania danych.

b) Wykresy

Aby lepiej zobrazować dane użyto wykresów pudełkowych w celu detekcji tzw. *outlierów*.

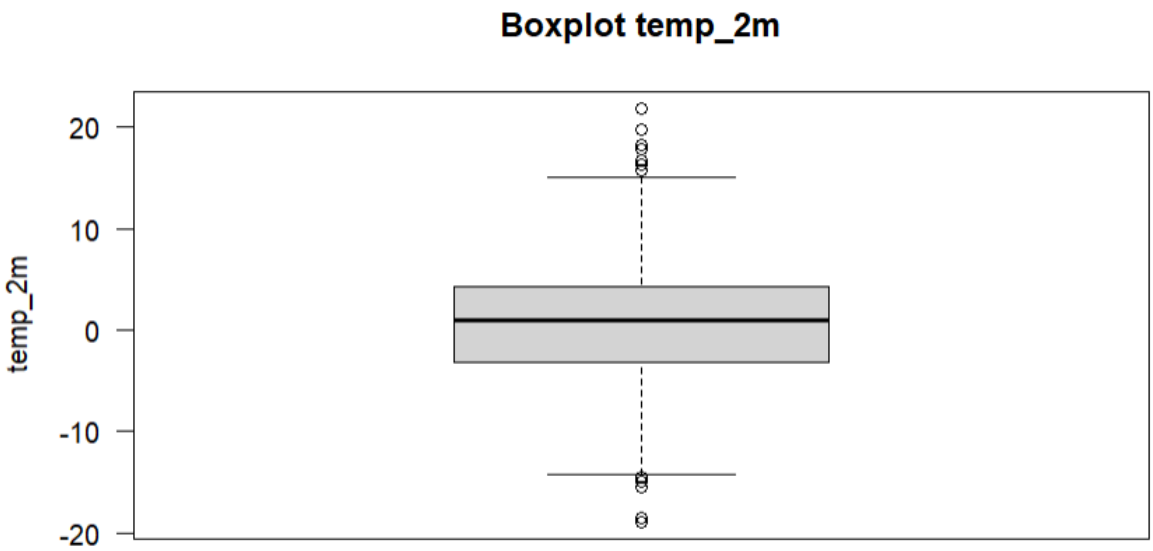

Mimo tego, że tak jak widać na powyższym wykresie, ***występowały wartości odstające*** zdecydowano się ich nie usuwać, ponieważ wartości te są *możliwe do osiągnięcia i nie noszą znamion błędów*. Usunięcie tych obserwacji mogłoby skutkować ***pominięciem ważnych wyników badań***. Dodatkowo dane użyto

już do przeprowadzania badań, więc to też zwiększa szanse na to, że są one dobrze przygotowane.

3.2 Sprawdzenie wartości brakujących

Zdecydowano się na sprawdzenie, czy w dostępnych atrybutach pojawiają się jakieś ***missing values***. Jest to istotny krok, ponieważ takie braki mogą uniemożliwić późniejszą analizę. Takie dane mogą się pojawić np. w wyniku jakichś *błędów urządzeń pomiarowych* czy przez *połączenie danych z różnych źródeł*.
W tym wypadku, jak opisane było wyżej, dane *były już używane w badaniach*, więc były już wstępnie obrabiane. Zatem nie pojawiły się w nich żadne brakujące wartości. Mimo to, zdecydowano się wykonać takie sprawdzenie.

3.3 Transformacje danych

Z opisu danych wynika, że atrybuty dotyczące *godzinowych wartości stężenia cząstek PM10* i *liczby samochodów na godzinę* zostały ***zlogarytmizowane***.
Aby użyć algorytmu ***RandomForest*** do klasyfikacji zdecydowano się na przekształcenie zmiennej *log_PM10* na zmienną *jakościową*. Zmienna ta została wcześniej zlogarytmizowana za pomocą *logarytmu naturalnego*. Podjęto decyzję o utworzeniu *dwóch etykiet* opisujących poziom stężenia: '***norma***' *(< 50 µg / m^3)* i '***przekroczono***' *(≥ 50 µg / m^3)*. Ponadto nie ma potrzeby *standaryzacji danych*, ponieważ ***drzewa decyzyjne nie są oparte na odległościach euklidesowych***, więc są odporne na nieustandaryzowane dane. Ponadto zdecydowano się na podstawie cechy '***hour***' utworzyć nową cechę '***day_part***', która przyjmuje odpowiednio etykiety: '***night***', '***morning***', '***afternoon***' i '***evening***'. Ma to na celu dodatkowego *sprawdzenia wpływu działania pory dnia na tworzony model*.

4. Modelowanie

Norma	Przekroczono
386	*114*
77,2%	*22,8%*

Sprawdzono *liczebność* etykiet dla zmiennej ***PM10***. Analiza ta wykazała istotną *nierównowagę klas*. Zdecydowaną większość (***77,2%***) stanowią przypadki spełniające normę jakości powietrza, natomiast obserwacje z przekroczonym dopuszczalnym poziomem stężenia PM10 występują znacznie rzadziej (***22,8%***). Taki rozkład jest ***charakterystyczny dla danych środowiskowych***, w których sytuacje alarmowe pojawiają się *sporadycznie*.

W przypadku takich *niezbalansowanych* danych stosowanie wyłącznie miary ***Accuracy*** może prowadzić do *mylących wniosków*. Model może osiągać *wysoką ogólną dokładność*, jednocześnie *bardzo słabo identyfikując obserwacje należące do klasy mniejszościowej*, które z punktu widzenia analizy są ***najistotniejsze***. Z tego względu ocena jakości modeli została oparta nie tylko na ***Accuracy***, lecz również na miarach liczonych osobno dla poszczególnych klas, takich jak ***Recall*** dla klasy '*przekroczono*', ***Specificity*** oraz ***Balanced Accuracy***, która uwzględnia nierównowagę klas.

4.1 Random Forest

Dane zostały podzielone na *trzy podzbiory*: zbiór ***uczący***, zbiór ***walidacyjny*** oraz zbiór ***predykcyjny*** składający się z ***4 obserwacji***. Podział na zbiór uczący i walidacyjny wykonano z zastosowaniem ***stratyfikacji*** względem zmiennej zależnej ***PM10***, co pozwoliło *zachować zbliżone proporcje klas w obu zbiorach* i zapewnić wiarygodną ocenę jakości modelu.

Ze względu na *niezbalansowany rozkład klas* zastosowano w modelu ***wagi klas*** (*classwt*), które zwiększają „koszt" błędnej klasyfikacji klasy mniejszościowej ('***exceed***'). Celem tego zabiegu *było poprawienie zdolności modelu do wykrywania przekroczeń normy PM10*, nawet kosztem *większej liczby* ***fałszywych alarmów***. Również z tego powodu zastosowano *obniżenie progu decyzyjnego* do poziomu ***0,23***. Pozwoliło to *zwiększyć czułość modelu dla klasy mniejszościowej kosztem spadku specyficzności*.

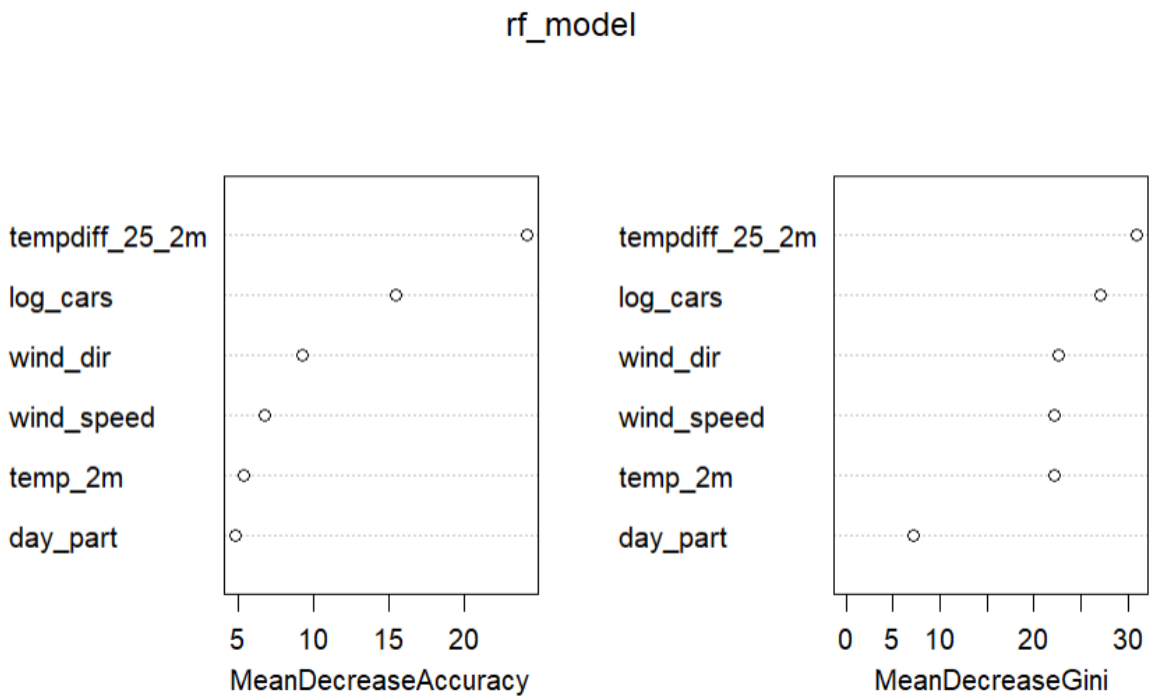

Po wytrenowaniu modelu zdecydowano się na wykonanie ***wykresu istotności zmiennych***, który *przedstawia względny wpływ poszczególnych zmiennych niezależnych na działanie* ***Random Forest***. Zaprezentowano dwie miary ważności: ***Mean Decrease Accuracy***, określającą *spadek dokładności klasyfikacji po losowej permutacji danej zmiennej* oraz ***Mean Decrease Gini***, opisującą *łączny wkład zmiennej w poprawę jednorodności węzłów w drzewach decyzyjnych*.

Największą istotnością w obu miarach charakteryzuje się zmienna '***tempdiff_25_2m***', co wskazuje, że różnica temperatur pomiędzy 25 a 2 metrami nad poziomem gruntu *ma istotne znaczenie w rozróżnianiu przypadków przekroczenia normy PM10*. Wysoką ważność wykazują również zmienne '***log_cars***' oraz '***wind_dir***', co sugeruje istotny wpływ natężenia ruchu drogowego oraz kierunku wiatru na poziom zanieczyszczenia powietrza. Zmienne '***wind_speed***', '***temp_2m***' oraz '***day_part***' cechują się relatywnie mniejszym, ale niezerowym wkładem w proces decyzyjny modelu.

4.2 Drzewo decyzyjne typu CART

Jako alternatywny model klasyfikacyjny zastosowano ***drzewo klasyfikacyjne CART***. Model został wytrenowany na zbiorze uczącym z wykorzystaniem tego samego zestawu zmiennych objaśniających, co w ***Random Forest***, co umożliwia bezpośrednie porównanie ich skuteczności. Ze względu na niezbalansowany rozkład klas zastosowano ***macierz strat***, *zwiększając koszt błędnej klasyfikacji klasy '**exceed**'*. Celem tego zabiegu również było *ukierunkowanie modelu na wykrywanie przypadków przekroczenia normy PM10*.

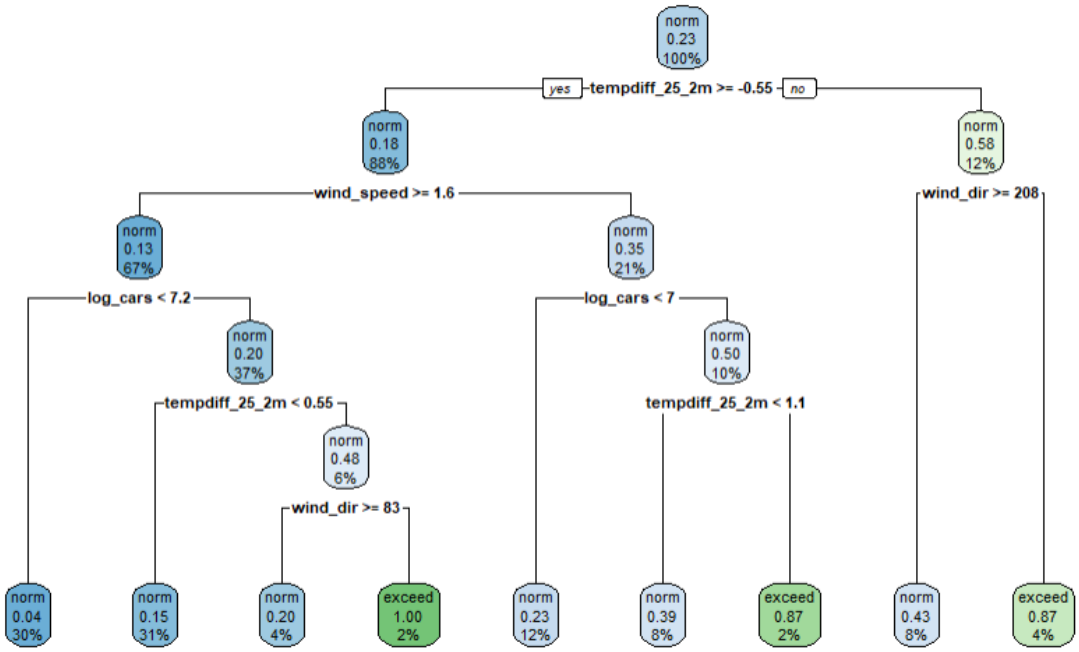

Wizualizacja ***drzewa CART*** umożliwia *bezpośrednią interpretację reguł decyzyjnych prowadzących do klasyfikacji obserwacji*. Pierwsze podziały drzewa wskazują na *istotną rolę zmiennej* '***tempdiff_25_2m***', a następnie ***prędkości wiatru***, ***natężenia ruchu drogowego*** oraz ***kierunku wiatru***. ***Zielone*** *liście* drzewa odpowiadają przypadkom sklasyfikowanym jako '***exceed***', natomiast ***niebieskie*** jako '***norm***'. Drzewo ujawnia konkretne *kombinacje warunków meteorologicznych i komunikacyjnych sprzyjające wystąpieniu* ***podwyższonego stężenia PM10***.

5. Ocena jakości modelu

5.1 Random Forest

Jakość modelu ***Random Forest*** oceniono na *zbiorze walidacyjnym*, który nie był wykorzystywany w procesie uczenia modelu. Ze względu na niezbalansowany charakter danych oraz *istotność poprawnej identyfikacji przypadków przekroczenia normy PM10*, ocena modelu została oparta na miarach liczonych osobno dla poszczególnych klas. Dla klasy '***exceed***' uzyskano wartość ***Recall*** równą ***0,71***, co oznacza, że model poprawnie identyfikuje ponad *70% rzeczywistych przekroczeń normy PM10*. ***Specificity*** wyniosła ***0,77***, co wskazuje na *umiarkowany wzrost liczby fałszywych alarmów*. ***Balanced Accuracy*** osiągnęła wartość ***0,74***, potwierdzając *dobrą zdolność modelu do rozróżniania klas przy uwzględnieniu ich nierównowagi*.

Uzyskany ***kompromis*** pomiędzy ***Recall*** a ***Specificity*** oceniono jako korzystny z punktu widzenia monitoringu jakości powietrza, gdzie ***pominięcie rzeczywistego przekroczenia normy jest bardziej kosztowne niż błędna sygnalizacja zagrożenia***.

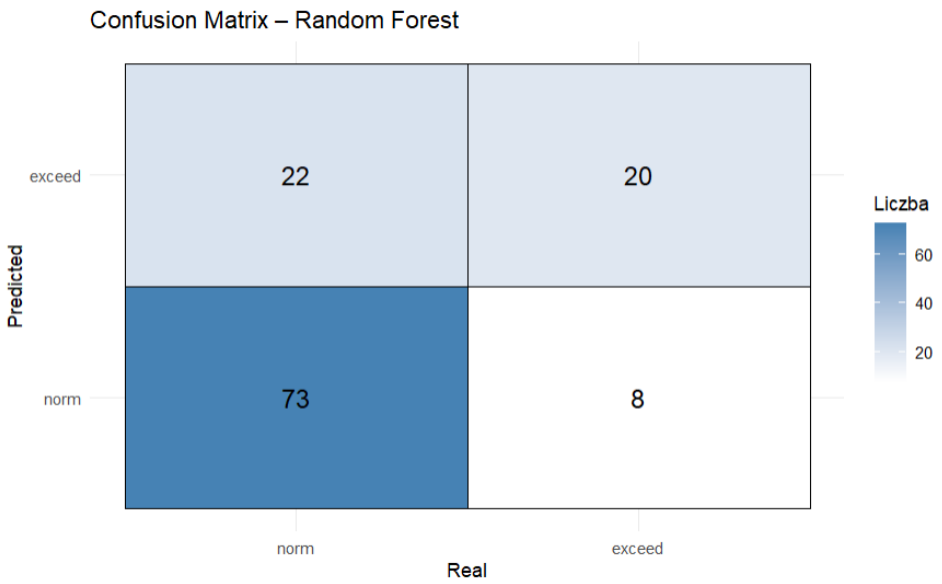

Dla zwiększenia czytelności wyników przedstawiono macierz pomyłek w formie graficznej.

5.2 Drzewo decyzyjne typu CART

Jakość modelu ***CART*** również oceniono na zbiorze ***walidacyjnym*** przy użyciu ***macierzy pomyłek*** oraz ***metryk*** istotnych w przypadku *niezbalansowanych danych*. Model osiągnął ***Specificity*** na poziomie ***0,82***, co oznacza *dobrą zdolność rozpoznawania przypadków spełniających normę jakości powietrza*. Jednocześnie ***Recall*** dla klasy '***exceed***' wynosi ***0,61***, co wskazuje, że model *wykrywa około 60% rzeczywistych przekroczeń normy PM10*. Wartość ***Balanced Accuracy*** na poziomie ***0,71*** potwierdza umiarkowaną zdolność modelu do rozróżniania klas przy uwzględnieniu ich nierównowagi. Oznacza to, że drzewo decyzyjne CART, po zastosowaniu macierzy strat oraz odpowiedniego progu decyzyjnego, potrafi w rozsądnym stopniu identyfikować zarówno przypadki spełniające normę, jak i sytuacje przekroczeń.

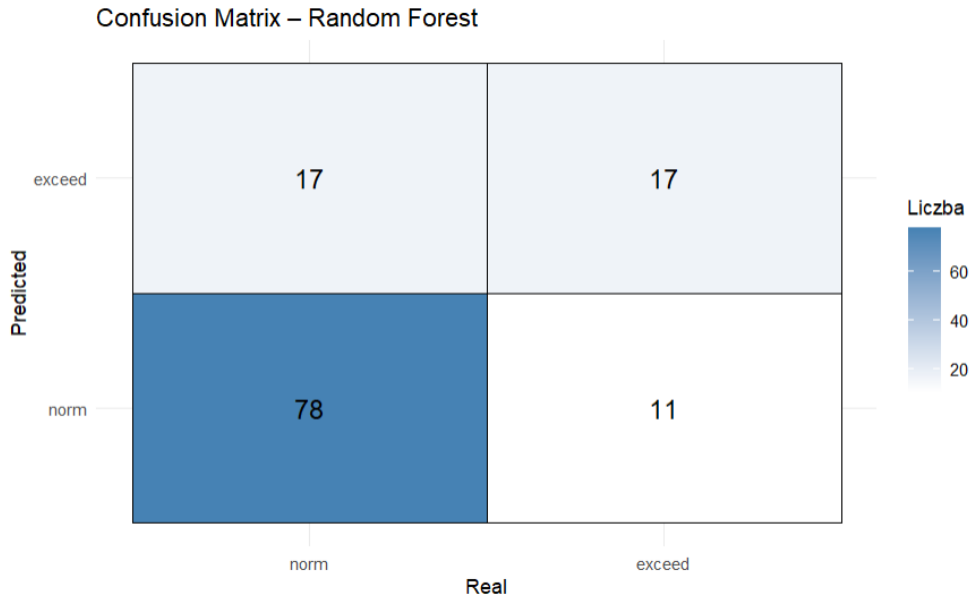

Analiza ***Confusion Matrix*** pokazuje, ze model ***CART*** *generuje pewną liczbę* ***fałsyzwych alarmów****,* co przekłada się na ***umiarkowaną precyzję*** *klasy '****exceed****' (****0.5****)*. Jednocześnie liczba błędów typu **False Negative**, czyli przypadków rzeczywistego przekroczenia normy PM10 zaklasyfikowanych jako '***norm***', została ograniczona. Z punktu widzenia ***monitoringu jakości powietrza*** jest to istotne, ponieważ *pominięcie rzeczywistego przekroczenia normy stanowi błąd bardziej niepożądany niż błędna sygnalizacja zagrożenia*.

6. Testowanie predykcji modeli

6.1 Random Forest

Predykcję modelu ***Random Forest*** przetestowano na niezależnym zbiorze ***czterech obserwacji***, *niewykorzystywanych wcześniej w procesie uczenia ani walidacji*.
Dla każdej obserwacji wyznaczono prawdopodobieństwo przynależności do klasy „***exceed***" (***P_exceed***) oraz przypisano klasę końcową przy zastosowaniu *progu decyzyjnego* ***0,23***.

W ***trzech*** przypadkach model ***poprawnie*** *zaklasyfikował obserwacje* jako spełniające normę jakości powietrza, przypisując im *niskie prawdopodobieństwo przekroczenia normy*. W jednym przypadku model wskazał ***przekroczenie normy,***
mimo *rzeczywistej klasy* „**norm**", co stanowi przykład ***fałszywego alarmu będącego konsekwencją obniżonego progu decyzyjnego***.

6.2 Drzewo decyzyjne typu CART

Na tym samym zbiorze czterech obserwacji przetestowano również model CART.
Dla każdej obserwacji wyznaczono prawdopodobieństwo przynależności do klasy „***exceed***" (***P_exceed***) oraz przypisano klasę końcową przy zastosowaniu *progu decyzyjnego* ***0,23***.

Na tak małym zbiorze testowym wyniki są takie same jak dla modelu ***Random Forest***, czyli ***trzy*** przypadki zostały *sklasyfikowane poprawnie*.

7. Porównanie modeli

Przeanalizowano dwa *modele klasyfikacyjne* oparte na ***drzewach decyzyjnych***: model ***Random Forest***, przydzielony losowo w ramach zadania, oraz wybrany samodzielnie model ***drzewa decyzyjnego typu CART***. *Oba modele trenowano na tym samym zbiorze danych oraz oceniano przy użyciu tych samych metryk jakości, istotnych w przypadku niezbalansowanej klasyfikacji*.

Model ***Random Forest*** charakteryzował się ***lepszą*** *zdolnością identyfikacji klasy mniejszościowej* '***exceed***', osiągając wyższą wartość ***Recall*** (***0,71***) oraz ***Balanced Accuracy*** (***0,74***). Oznacza to, że model ten *skuteczniej wykrywał rzeczywiste przekroczenia normy PM10*, *przy jednoczesnym zachowaniu akceptowalnego poziomu błędnych alarmów*.

Model ***CART*** osiągnął ***niższą*** wartość ***Balanced Accuracy*** (***0,71***) oraz ***Recall*** (***0,61***), co wskazuje na *umiarkowaną skuteczność w wykrywaniu przekroczeń normy PM10*. Jednocześnie cechował się *dobrą zdolnością klasyfikacji przypadków spełniających normę jakości powietrza, co potwierdza wysoka wartość* ***Specificity*** *(**0,82**)*.
Mimo to, w kontekście ***monitoringu jakości powietrza***, gdzie kluczowe znaczenie

ma *identyfikacja zdarzeń niebezpiecznych*, model ***CART*** okazał się ***mniej efektywny***.

Na podstawie przeprowadzonych analiz stwierdzono, że ***Random Forest jest lepiej dopasowanym modelem do analizowanego problemu***, szczególnie w kontekście wykrywania rzadkich, ale istotnych przypadków przekroczenia normy PM10.

Źródła:
https://pl.wikipedia.org/wiki/PM10
https://airly.org/pl/pyl-zawieszony-czym-jest-pm10-a-czym-pm2-5-aerozole-atmosferyczne/